



Aprendizaje Automatico

SI7009 - 1 (5553)
Universidad EAFIT

Juan David Torres
jdtorres@eafit.edu.co



01 PANORAMA DEL CURSO

02 EVALUACIÓN MODERNA,
DESBALANCE Y CRITERIO

03 WORKFLOW CORRECTO Y
BASELINE

04 ARBOLES DE DECISIÓN

05 ENSEMBLE LEARNING

06 DESBALANCE, MATRIZ DE
CONFUSION Y METRICAS

07 ROC, PR Y THRESHOLD
OPERATIVO

08 ESTRATEGIAS MINIMAS
PARA DESBALANCE

CONTENIDO DE LA CLASE


01

PANORAMA DEL CURSO

OBJETIVOS DE APRENDIZAJE

Aprender principios del aprendizaje automático, técnicas convencionales de preprocesamiento de datos, algoritmos básicos de ML y evaluación de modelos.

Familiarizarse con métodos tradicionales de ML y librerías de preprocesamiento de datos, incluyendo métodos para detectar y corregir el sobre-entrenamiento



¿COMO VAMOS A APRENDER?

PRESENTACIONES

Narrativa conceptual, errores frecuentes, criterios de decisión.

NOTEBOOKS

Demos reproducibles en Python con datasets reales.

TALLER PRACTICO

Decisiones técnicas aplicadas al taller, exposición y proyecto integrador.

SISTEMA DE EVALUACIÓN

COMPONENTE	PESO	QUE EVALÚA
Taller modular único	20%	Formulación, validación, comparación, threshold y decisión final
Exposición avanzada	20%	Comunicación técnica, ejemplo en Python y reproducibilidad
Examen final	25%	Comprensión conceptual individual y juicio metodológico
Proyecto Integrador	30%	Aporte analítico defendible dentro del Proyecto Integrador

Idea clave: Criterio. La evaluación mide criterio técnico, no recitación de algoritmos

ROADMAP DE LAS SESIONES

SESIÓN	TEMA CENTRAL	DATASET / ARTEFACTO GUÍA
1	Evaluación, desbalance, métricas y fundamento de ensembles	Fraude transaccional
2	Boosting moderno e HPO con validación correcta	Fraude + Optuna
3	Series de tiempo y walk-forward validation	Tráfico / serie temporal
4	Recommendation systems y top-N	MovieLens
5	Clustering, representación, outliers, calibration y drift	Online Retail + fraude

PROYECTO INTEGRADOR 1: QUÉ ES Y QUÉ EXIGE

Definición: Idea central

Proyecto transversal para resolver una problemática real con datos reales, integrando modelado, tecnología y comunicación.

- Vale 35 % de cada materia
- Debe seguir una metodología explícita: problema, datos, preparación, modelado, evaluación y despliegue
- Cada equipo debe definir temprano: problema, fuentes de datos, restricciones y ruta de solución

IDEA CLAVE: APORTE POR CURSO

Aprendizaje Automático: baseline, modelos, validación e interpretación

Big Data: arquitectura, pipeline y despliegue

Visualización: app/dashboard, pitch y defensa

QUÉ SE EVALÚA Y QUÉ DEBEN ENTREGAR

TALLER / TAREA: ENTREGABLES FINALES

- Documento consolidado
- Notebook completado
- GitHub reproducible

HERRAMIENTA: RÚBRICA MÍNIMA EN APRENDIZAJE AUTOMÁTICO

- problema y target claros
- baseline explícito
- validación correcta
- modelos pertinentes
- análisis de resultados

Exposiciones: mini-system

Rol en el curso

Componente formal del curso que vale 20 %. No reemplaza la clase: amplía el horizonte con temas modernos no cubiertos de forma central en las cinco sesiones.

Taller

- Asignación por orden de escogencia
- Individual o en pareja
- Tríos solo si la matrícula lo exige
- Un tema no se repite hasta agotar el banco
- Cierre de escogencia: final de Sesión 2

Entrega mínima

- PDF
- GitHub público reproducible
- 20 min de exposición + 5 min de preguntas
- Participación equilibrada

BANCO DE TEMAS OFICIAL

LINEA	TEMAS DISPONIBLES
Base	Sistemas de recomendación avanzados; aprendizaje por refuerzo; aprendizaje semi-supervisado; aprendizaje federado; MLOps / deployment; clasificación altamente desbalanceada; restricciones en modelos; XAI
Expansión	Graph Neural Networks; Learning to Rank; uplift modeling y causal ML; active learning; continual learning; time-series transformers; tabular deep learning; AutoML y meta-learning
Avanzados	Synthetic data; privacy-preserving ML; fairness; anomaly detection at scale; survival analysis; multi-objective optimization; weak supervision; foundation models tabulares o temporales
Sistemas	Retrieval-augmented ML systems; ML para grafos dinámicos; bandits contextualizados; conformal prediction; uncertainty quantification; TinyML / energy-efficient ML

FECHAS DOCENTES

25/09 ————— **1** -----> PRIMERA SESIÓN - HOY

SEGUNDA SESIÓN - ELEGIR TEMA EXPO <----- **2** ————— **26/09**

02/10 ————— **3** -----> TERCERA SESIÓN

CUARTA SESIÓN <----- **4** ————— **03/10**

FECHAS DOCENTES

09/10 ————— **5** -----> QUINTA SESIÓN - ENTREGA TALLER

ULTIMA SESION - EXPOSICIONES <----- **6** ————— **10/10**

23/11 ————— **7** -----> SUSTENTACIÓN PROYECTO INTEGRADOR
PREGRADO

SUSTENTACIÓN PROYECTO
INTEGRADOR MAESTRÍA <----- **8** ————— **30/11**



5 sesiones
intensivas



decisiones
defendibles

Aprendizaje Automático



slides



notebooks



datasets
reales



criterio
metodológico



20%
taller



20%
exposición



25%
examen



35%
PI



Poblado,
Bloque 17,
Aula 303





02

EL PROCESO DE
ENTRENAMIENTO:
UNDERFITTING,
OVERFITTING, TESTING
& REGULARIZACIÓN

ADVANCED ML WORKFLOW

TRAINING → EVALUATION → INFERENCE




EL PROBLEMA: EXTREMOS EN EL ENTRENAMIENTO


El underfitting se parece mucho a no haber estudiado lo suficiente para un examen.

El sobreajuste se parece mucho a memorizar todo el libro de texto en lugar de estudiar para el examen.


Un buen modelo, uno que ni se queda corto ni se sobreajusta, es aquel que parece haber estudiado bien para el examen.



UN EJEMPLO DE UNDERFITTING Y OVERFITTING MEDIANTE LA REGRESIÓN POLINÓMICA




UN EJEMPLO DE UNDERFITTING Y OVERFITTING MEDIANTE LA REGRESIÓN POLINÓMICA




Model 1

Polynomial of degree 1
(a line)



Model 2


Polynomial of degree 2
(a parabola)




Model 3

Polynomial of degree 10

UN EJEMPLO DE UNDERFITTING Y OVERFITTING MEDIANTE LA REGRESIÓN POLINÓMICA



¿CÓMO LOGRAMOS QUE LA COMPUTADORA ELIJA EL MODELO CORRECTO?



LA REGLA DE ORO

JAMÁS USARÁS
TUS DATOS DE
PRUEBA PARA
ENTRENAR

UNA FORMA NUMÉRICA DE DECIDIR QUÉ TAN COMPLEJO DEBE SER NUESTRO MODELO: EL GRÁFICO DE COMPLEJIDAD DEL MODELO

Polynomial

Degree

9

0

$$x^1 + 4$$

1

$$x^2 + x^1 + -5$$


2

$$2x^3 + 11x^2$$

3

$$x^2y^3 + 6x^4 + y^1$$

5



OTRA ALTERNATIVA PARA EVITAR EL SOBREAJUSTE: LA REGULARIZACIÓN

Rendimiento (En mL de agua filtrada)

Trabajador 1: 1000 mL de agua

Trabajador 2: 1 mL de agua

Trabajador 3: 0 mL de agua




Problem: Broken roof



Roofer 1

Solution: Bandage
(Underfitting)



Roofer 2

Solution: Shingles
(Correct)



Roofer 3

Solution: Titanium
(Overfitting)

NECESITAMOS UNA MEDIDA DE LA COMPLEJIDAD QUE NOS AYUDE A TOMAR LA DECISIÓN CORRECTA

Complejidad (el precio)

Trabajador 1: \$1

Trabajador 2: \$100

Trabajador 3: \$100,000




Problem: Broken roof



Roofer 1

Solution: Bandage
(Underfitting)



Roofer 2

Solution: Shingles
(Correct)



Roofer 3

Solution: Titanium
(Overfitting)

LO QUE NECESITAMOS ES COMBINAR LAS MEDIDAS DE RENDIMIENTO Y COMPLEJIDAD

Rendimiento + complejidad

Trabajador 1: 1001

Trabajador 2: 101

Trabajador 3: 100,000




Problem: Broken roof



Roofer 1

Solution: Bandage
(Underfitting)



Roofer 2

Solution: Shingles
(Correct)



Roofer 3

Solution: Titanium
(Overfitting)

OTRO EJEMPLO DE OVERFITTING: RECOMENDACIONES DE PELÍCULAS

Imaginen un sistema de recomendación donde tenemos solo 10 películas (Peli1, Peli2, ..., Peli10), y solo 100 usuarios y sus tiempos de reproducción de cada película como variables. Queremos predecir las vistas de una nueva película (Peli11) basándonos en el tiempo de reproducción de las anteriores (Peli1 a Peli10). Usaremos un modelo de regresión lineal para estimar el tiempo que un usuario verá la Peli11.

$$\hat{y} = w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + w_5x_5 + w_6x_6 + w_7x_7 + w_8x_8 + w_9x_9 + w_{10}x_{10} + b,$$

where

- $\hat{y}$ is the amount of time the model predicts that the user will watch movie 11,
- x_i is the amount of time the user watched movie i , for $i = 1, 2, \dots, 10$,
- w_i is the weight associated to movie i , and
- b is the bias.

OTRO EJEMPLO DE OVERFITTING: RECOMENDACIONES DE PELÍCULAS

Ahora pongamos a prueba nuestra intuición. De los dos modelos siguientes (dados por su ecuación), ¿cuál parece que podría sufrir de overfitting?

Model 1: $\hat{y} = 2x_3 + 1.4x_7 - 0.5x_7 + 4$

Model 2: $\hat{y} = 22x_1 - 103x_2 - 14x_3 + 109x_4 - 93x_5 + 203x_6 + 87x_7 - 55x_8 + 378x_9 - 25x_{10} + 8$

Nuestro objetivo es tener un modelo como el modelo 1 y evitar modelos como el modelo 2. Pero, desafortunadamente, si el modelo 2 produce un error menor que el modelo 1, al ejecutar el algoritmo de regresión lineal se seleccionará el modelo 2 en su lugar.

CÓMO MEDIR LA COMPLEJIDAD DE UN MODELO: LAS NORMAS L1 Y L2

Observen que un modelo con más coeficientes, o con coeficientes de mayor valor, tiende a ser más complejo.

Model 1: $\hat{y} = 2x_3 + 1.4x_7 - 0.5x_7 + 4$

Model 2: $\hat{y} = 22x_1 - 103x_2 - 14x_3 + 109x_4 - 93x_5 + 203x_6 + 87x_7 - 55x_8 + 378x_9 - 25x_{10} + 8$

Por lo tanto, cualquier fórmula que cumpla con esto funcionará, como la siguiente:

- La suma de los valores absolutos de los coeficientes
- La suma de los cuadrados de los coeficientes

La primera se llama norma L1 y la segunda, norma L2.

MIDIENDO LA COMPLEJIDAD: NORMAS L1 Y L2

Model 1: $\hat{y} = 2x_3 + 1.4x_7 - 0.5x_7 + 4$

Model 2: $\hat{y} = 22x_1 - 103x_2 - 14x_3 + 109x_4 - 93x_5 + 203x_6 + 87x_7 - 55x_8 + 378x_9 - 25x_{10} + 8$

L1 norm:

- **Model 1:** $|2| + |1.4| + |-0.5| = 3.9$
- **Model 2:** $|22| + |-103| + |-14| + |109| + |-93| + |203| + |87| + |-55| + |378| + |-25| = 1,089$

L2 norm:

- **Model 1:** $2^2 + 1.4^2 + (-0.5)^2 = 6.21$
- **Model 2:** $22^2 + (-103)^2 + (-14)^2 + 109^2 + (-93)^2 + 203^2 + 87^2 + (-55)^2 + 378^2 + (-25)^2 = 227,131$

MIDIENDO LA COMPLEJIDAD: LAS NORMAS L1 Y L2

Un modelo con más coeficientes, o coeficientes de mayor valor, tiende a ser más complejo. Medimos esto usando normas matemáticas (espacios de Lebesgue):

Norma L1: Suma de los valores absolutos de los coeficientes.

$$L1 = \|w\|_1 = \sum_i |w_i|$$

Norma L2: Suma de los cuadrados de los coeficientes.

$$L2 = \|w\|_2 = \sqrt{\sum_i (w_i)^2}$$

Alert Box

Consideración Técnica: El sesgo (bias/intersección) nunca se incluye en el cálculo de las normas. El sesgo representa una predicción base, no una medida de la complejidad del modelo.


REGULARIZACIÓN

Error de la regresión

Una medida de la calidad del modelo. En este caso, puede tratarse del error absoluto o del error al cuadrado


término de regularización

Una medida de la complejidad del modelo. Puede ser la norma L1 o la norma L2 del modelo.


$$\text{Error} = \text{Regression error} + \lambda \text{ Regularization term}$$

$$\text{Lasso regression error} = \text{Regression error} + \lambda \text{ L1 norm}$$


$$\text{Ridge regression error} = \text{Regression error} + \lambda \text{ L2 norm}$$



EVALUACIÓN MODERNA,
DESBALANCE Y
CRITERIO




ACCURACY: ¿CON QUÉ FRECUENCIA MI MODELO ACIERTA?

correct predictions



37

Accuracy =




45

all predictions


FALSOS POSITIVOS Y FALSOS NEGATIVOS: ¿CUÁL ES PEOR?

Coronavirus model



Diagnosed healthy


Diagnosed sick



False negative:
Sick person
not treated


False positive:
Healthy person
sent for more tests

Spam model



Classified ham

Classified spam




False negative:
Spam email
sent to inbox


False positive:
Ham email
sent to spam folder

EL COSTO DE LOS ERRORES

Modelo Médico (Coronavirus)



Modelo de Email (Spam)



Falso Positivo (FP)

Diagnosticar a un sano como enfermo.
Costo: Molestia menor, pruebas extra.

Enviar correo legítimo al spam.
Costo: Desastre (pérdida de información crítica).

Falso Negativo (FN)

Diagnosticar a un enfermo como sano.
Costo: Alto riesgo, brote de infección.

Dejar pasar un spam a la bandeja.
Costo: Ligera molestia visual.

ALMACENANDO LOS ACIERTOS Y FALLOS EN UNA TABLA: LA MATRIZ DE CONFUSIÓN

Definición: Tabla estructurada que categoriza y almacena las predicciones correctas e incorrectas de un modelo binario.

Predicción del Modelo	
Condición Real	VP: Verdaderos Positivos (Correcto)
	FN: Falsos Negativos (Error Tipo II)
Condición Real	FP: Falsos Positivos (Error Tipo I)
	VN: Verdaderos Negativos (Correcto)

ALMACENANDO LOS ACIERTOS Y FALLOS EN UNA TABLA: LA MATRIZ DE CONFUSIÓN

Definición: Tabla estructurada que categoriza y almacena las predicciones correctas e incorrectas de un modelo binario.

Predicción del Modelo	
Condición Real	VP: Verdaderos Positivos (Correcto)
	FN: Falsos Negativos (Error Tipo II)
Condición Real	FP: Falsos Positivos (Error Tipo I)
	VN: Verdaderos Negativos (Correcto)

MATRIZ DE CONFUSIÓN DE NUESTRO MODELO DE CORONAVIRUS

Coronavirus model 1	Diagnosed sick (predicted positive)	Diagnosed healthy (predicted negative)
Sick (positive)	0 (number of true positives)	10 (number of false negatives)
Healthy (negative)	0 (number of false positives)	990 (number of true negatives)

RECALL: DE ENTRE LOS EJEMPLOS POSITIVOS,
¿CUÁNTOS CLASIFICAMOS CORRECTAMENTE?

Coronavirus model 1	Diagnosed sick (predicted positive)	Diagnosed healthy (predicted negative)
Sick (positive)	0 (number of true positives)	10 (number of false negatives)
Healthy (negative)	0 (number of false positives)	990 (number of true negatives)

$$\text{Recall} = \frac{\text{True positives}}{\text{True positives} + \text{False negatives}}$$

LA MATRIZ DE CONFUSIÓN DE NUESTRO SEGUNDO MODELO DEL CORONAVIRUS

Coronavirus model 2	Diagnosed sick	Diagnosed healthy
Sick	8 (true positives)	2 (false negatives)
Healthy	48 (false positives)	942 (true negatives)

El Recall de este modelo es el número de verdaderos positivos (ocho personas enfermas diagnosticadas correctamente) dividido entre el número total de positivos (10 personas enfermas), lo que da $8/10 = 0,8$, o el 80 %. En cuanto a la capacidad de detección, el segundo modelo es mucho mejor.

COMPARATIVA MODELOS DEL CORONAVIRUS

Modelo 1:

Verdaderos positivos (pacientes enfermos) = 0

Falsos negativos (pacientes enfermos a quienes se les diagnosticó que estaban sanos) = 10

Recall = $0/10 = 0\%$

Modelo 2:

Verdaderos positivos (pacientes enfermos diagnosticados como tales) = 8

Falsos negativos (pacientes enfermos diagnosticados como sanos) = 2

Recall = $8/10 = 80\%$

Coronavirus model 1	Diagnosed sick (predicted positive)	Diagnosed healthy (predicted negative)
Sick (positive)	0 (number of true positives)	10 (number of false negatives)
Healthy (negative)	0 (number of false positives)	990 (number of true negatives)

Coronavirus model 2	Diagnosed sick	Diagnosed healthy
Sick	8 (true positives)	2 (false negatives)
Healthy	48 (false positives)	942 (true negatives)

RECALL: DE TODOS LOS CASOS QUE EL MODELO
PREDIJO COMO POSITIVOS, ¿CUÁNTOS LO ERAN
REALMENTE?

$$\textit{Precision} = \frac{\textit{True positives}}{\textit{True positives} + \textit{False positives}}$$

COMPARATIVA MODELOS ANTISPAM

Modelo 1:

Spam model 1	Predicted spam	Predicted ham
Spam	30 (true positives)	10 (false negatives)
Ham	5 (false positives)	55 (true negatives)

Modelo 2:

Spam model 2	Predicted spam	Predicted ham
Spam	35 (true positives)	5 (false negatives)
Ham	10 (false positives)	50 (true negatives)

COMPARATIVA MODELOS ANTISPAM

Modelo de spam 1:

- Verdaderos positivos (spam eliminado) = 30
- Falsos positivos (correos legítimos eliminados) = 5
- Precisión = $30/35 = 85,7 \%$


Spam model 1	Predicted spam	Predicted ham
Spam	30 (true positives)	10 (false negatives)
Ham	5 (false positives)	55 (true negatives)

Modelo de spam 2:

- Verdaderos positivos (spam eliminado) = 35
- Falsos positivos (correos legítimos eliminados) = 10
- Precisión = $35/45 = 77,7$

Spam model 2	Predicted spam	Predicted ham
Spam	35 (true positives)	5 (false negatives)
Ham	10 (false positives)	50 (true negatives)

COMBINAR RECALL Y LA PRECISIÓN COMO FORMA DE OPTIMIZAR AMBAS: EL F-SCORE



COMBINAR RECALL Y LA PRECISIÓN COMO FORMA
DE OPTIMIZAR AMBAS: EL F-SCORE

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

SENSIBILIDAD Y ESPECIFICIDAD: DOS NUEVAS FORMAS DE EVALUAR UN MODELO

Sensibilidad (tasa de verdaderos positivos): la capacidad de la prueba para identificar los puntos marcados como positivos.

Es la relación entre el número de verdaderos positivos y el número total de positivos. (Nota: este es el mismo recall).

$$Sensitivity = \frac{True\ positives}{True\ positives + False\ negatives}$$


Especificidad (tasa de negativos verdaderos): la capacidad de la prueba para identificar los puntos etiquetados como negativos.

Se trata de la relación entre el número de negativos verdaderos y el número total de negativos.

$$Specificity = \frac{True\ negatives}{True\ negatives + False\ positives}$$

LA MECÁNICA DEL UMBRAL (THRESHOLD)


Concepto: Los modelos de clasificación arrojan probabilidades (0 a 1). El umbral define el punto de corte para clasificar algo como "positivo". Al variar este umbral desde 0 hasta 1 y registrar la sensibilidad y la especificidad del modelo en cada valor de umbral obtenemos la curva ROC (receiver operating characteristic).



LA CURVA ROC RECEIVER OPERATING CHARACTERISTIC


Definición: Una representación gráfica del 'trade-off' entre Sensibilidad y Especificidad para cada umbral de probabilidad posible.

Step	True positives	Sensitivity	True negatives	Specificity
0	5	1	0	0
1	5	1	1	0.2
2	4	0.8	1	0.2
3	4	0.8	2	0.4
4	4	0.8	3	0.6
5	3	0.6	3	0.6
6	3	0.6	4	0.8
7	2	0.4	4	0.8
8	2	0.4	5	1
9	1	0.2	5	1
10	0	0	5	1




UNA MÉTRICA QUE NOS INDICA LA CALIDAD DE NUESTRO MODELO: EL AUC (ÁREA BAJO LA CURVA)


Definición: Una representación gráfica del 'trade-off' entre Sensibilidad y Especificidad para cada umbral de probabilidad posible.




RECALL ES LO MISMO QUE SENSIBILIDAD, PERO LA PRECISIÓN Y LA ESPECIFICIDAD SON DIFERENTES



LA CURVA PR (PRECISION-RECALL)





DESBALANCE DE CLASES

EL PROBLEMA DEL DESBALANCE DE CLASES

¿Cuándo ocurre?


- Detección de fraude: 0.1 % positivos
- Diagnóstico médico: enfermedades raras
- Predicción de churn: 5 % abandonan
- Detección de anomalías

¿Por qué es problemático?

- Modelo trivial (predecir siempre mayoría) obtiene alta accuracy
- Riesgo: ignorar la clase rara.
- Algoritmos sesgados hacia clase mayoritaria
- Métricas engañosas

CROSS-VALIDATION TECHNIQUES


El K-fold y el K-fold estratificado son técnicas de validación cruzada que se utilizan para evaluar el desempeño de los modelos de aprendizaje automático mediante la división de los datos en subconjuntos (folds)



K-FOLD ESTRATIFICADO

STRATIFIED K-FOLD CROSS-VALIDATION





ESTRATEGIAS PARA DATOS DESBALANCEADOS

01

Ajustes sólo en train; dev/test conservan distribución.

02

Undersampling: Submuestreo (reducción) de la clase mayoritaria.

03


Oversampling: Remuestreo (aumento) de clases minoritarias. Por medio de generación de datos sintéticos.

- SMOTE: Synthetic Minority Oversampling
- ADASYN: Adaptive Synthetic Sampling


04


Class weights: Ponderar la pérdida, penalizar más errores en minoría

UNDERSAMPLING



OVERSAMPLING






SMOTE
SYNTHETIC
MINORITY
OVER-
SAMPLING
TECHNIQUE

ESTRATEGIAS PARA DESBALANCE DE CLASES: INTERVENCIONES METODOLÓGICAS

class_weight

Ajuste de pesos en la pérdida para priorizar clase minoritaria



Ajuste de pesos en la pérdida para priorizar clase minoritaria

beneficio:


Simple,
eficiente

riesgo:

Sobreajuste a
patrones raros

undersampling

Reducción de muestras de la clase mayoritaria



beneficio:


Reduce sesgo
mayoritario,
acelera
entrenamiento

riesgo:

Pérdida de
información

oversampling

Réplica de muestras de la clase minoritaria existentes



beneficio:


Retiene información
mayoritaria,
aumenta visibilidad
minoritaria

riesgo:

Alto riesgo de
sobreajuste,
réplicas exactas

SMOTE

Generación de nuevos ejemplos
sintéticos entre vecinos
minoritarios cercanos



beneficio:

Crea diversidad
de ejemplos,
reduce réplicas
exactas

riesgo:

Generación
ruidosa

Fair comparson la etrategion (e.g., cross-validation,
or unified testing on an independiente hold-out set)

→ **validación**
no es receta


→ Entrenar
al modelo



→ Cálculo de
métricos




→ Análisis de
resultados



ARBOLES DE DECISION



¿QUÉ ES UN ÁRBOL DE DECISIÓN?

Un modelo predictivo que simula el razonamiento humano dividiendo los datos a través de una secuencia de operaciones binarias (preguntas de Sí/No).




¿CÓMO CONSTRUIMOS ESTE ÁRBOL?

¿Qué árbol nos parece mejor a la hora de decidir si nos ponemos o no una chaqueta?



CART (CLASSIFICATION AND REGRESSION TREES)


Algoritmo fundamental que construye árboles binarios mediante particiones recursivas que minimizan una función de costo.



Algoritmo Codicioso (Greedy): En cada paso, el modelo toma la mejor decisión local inmediata disponible. Prioriza la optimización instantánea en lugar de buscar exhaustivamente el árbol global perfecto.


¿Cuál sería una buena pregunta que nos ayude a decidir si debemos ponernos una chaqueta?

1. ¿Está lloviendo?
2. ¿Hace frío afuera?
3. ¿Tengo hambre?
4. ¿Hay un auto rojo afuera?
5. ¿Es lunes?



YA TENEMOS NUESTRO ÁRBOL DE DECISIÓN. ¿PODEMOS MEJORARLO?

1. ¿Cómo se decide exactamente cuál es la mejor pregunta posible que se puede hacer?
2. ¿El proceso de elegir siempre la mejor pregunta posible nos lleva realmente a construir el mejor árbol de decisión?
3. ¿Por qué no construimos, en cambio, todos los árboles de decisión posibles y elegimos el mejor de entre ellos?



UN SISTEMA DE RECOMENDACIÓN DE APLICACIONES

- Atom Count: una app que cuenta el número de átomos que hay en tu cuerpo
- Beehive Finder: una app que localiza tu ubicación y encuentra las colmenas más cercanas
- Check Mate Mate: una app para encontrar jugadores de ajedrez australianos



Atom Count



Beehive Finder



Check Mate Mate

UN CONJUNTO DE DATOS CON LOS USUARIOS DE UNA TIENDA DE APLICACIONES

Teniendo en cuenta esta tabla, ¿qué aplicación recomendarías a cada uno de los siguientes tres clientes?


- Cliente 1: usuario de iPhone de 13 años
- Cliente 2: usuario de iPhone de 28 años
- Cliente 3: usuario de Android de 34 años

Platform	Age	App
iPhone	15	Atom Count
iPhone	25	Check Mate Mate
Android	32	Beehive Finder
iPhone	35	Check Mate Mate
Android	12	Atom Count
Android	14	Atom Count

PRIMER PASO PARA CONSTRUIR EL MODELO: HACER LA MEJOR PREGUNTA


Platform	Age	App
iPhone	Young	Atom Count
iPhone	Adult	Check Mate Mate
Android	Adult	Beehive Finder
iPhone	Adult	Check Mate Mate
Android	Young	Atom Count
Android	Young	Atom Count

Classifier 1: By platform



Correct 4 out of 6 times
Accuracy: 66.67%

Classifier 2: By age



Correct 5 out of 6 times
Accuracy: 83.33%


ÍNDICE DE IMPUREZA DE GINI: ¿QUÉ TAN DIVERSO ES MI CONJUNTO DE DATOS?

El índice de Gini es una medida de la diversidad en un conjunto de datos. En otras palabras, si tenemos un conjunto en el que todos los elementos son similares, este conjunto tiene un índice de Gini bajo, y si todos los elementos son diferentes, tiene un índice de Gini alto.

Dos conjuntos de 10 bolas de colores

Para mayor claridad, consideremos los siguientes dos conjuntos de 10 bolas de colores (donde cualquier par de bolas del mismo color es indistinguible):

Conjunto 1




Composición del conjunto 1:

- 8 bolas rojas
- 2 bolas azules

{roja, roja, roja, roja, roja, roja, roja, roja, azul, azul}

Conjunto 2



Composición del conjunto 2:

- 4 bolas rojas
- 3 bolas azules
- 2 bolas amarillas
- 1 bola verde

{roja, roja, roja, roja, azul, azul, azul, amarilla, amarilla, verde}

ÍNDICE DE IMPUREZA DE GINI


En un conjunto con m elementos y n clases, en el que hay a_i elementos que pertenecen a la i -ésima clase, el índice de impureza de Gini es:

$$Gini = 1 - p_1^2 - p_2^2 - \dots - p_n^2,$$

$$p_i = \frac{a_i}{m}$$

Donde p_i puede interpretarse como la probabilidad de que, si elegimos dos elementos al azar del conjunto, estos pertenezcan a clases diferentes.

Conjunto 1




Composición del conjunto 1:

- 8 bolas rojas
- 2 bolas azules

{roja, roja, roja, roja, roja, roja, roja, roja, azul, azul}

Conjunto 2



Composición del conjunto 2:

- 4 bolas rojas
- 3 bolas azules
- 2 bolas amarillas
- 1 bola verde

{roja, roja, roja, roja, azul, azul, azul, amarilla, amarilla, verde}

PODEMOS CALCULAR EL ÍNDICE DE GINI PARA AMBOS CONJUNTOS


Conjunto 1: {rojo, rojo, rojo, rojo, rojo, rojo, rojo, rojo, azul, azul}
(ocho bolas rojas, dos bolas azules)

$$\text{Gini impurity index} = 1 - \left(\frac{8}{10}\right)^2 - \left(\frac{2}{10}\right)^2 = 1 - \frac{68}{100} = 0.32$$

Conjunto 2: {rojo, rojo, rojo, rojo, azul, azul, azul, amarillo, amarillo, verde}

$$\text{Gini impurity index} = 1 - \left(\frac{4}{10}\right)^2 - \left(\frac{3}{10}\right)^2 - \left(\frac{2}{10}\right)^2 - \left(\frac{1}{10}\right)^2 = 1 - \frac{30}{100} = 0.7$$

Conjunto 1




Composición del conjunto 1:

- 8 bolas rojas
- 2 bolas azules

{roja, roja, roja, roja, roja, roja, roja, roja, azul, azul}

Conjunto 2




Composición del conjunto 2:


- 4 bolas rojas
- 3 bolas azules
- 2 bolas amarillas
- 1 bola verde

{roja, roja, roja, roja, azul, azul, azul, amarilla, amarilla, verde}

¿CÓMO USAMOS GINI PARA DECIDIR COMO DIVIDIR LOS DATOS (POR EDAD O PLATAFORMA)?



Average Gini impurity index: 0.444



Average Gini impurity index: 0.222

ENTROPÍA: OTRA MEDIDA DE DIVERSIDAD, CON IMPORTANTES APLICACIONES EN LA TEORÍA DE LA INFORMACIÓN


La entropía calcula la probabilidad de obtener una secuencia exacta de elementos al extraerlos de un conjunto con reemplazo.

¿Cuál es la probabilidad de que, al sacar una bola al azar y regresar inmediatamente, obtengamos exactamente la secuencia que define el conjunto 1, que es {rojo, rojo, rojo, rojo, rojo, rojo, rojo, azul, azul}?

Dos conjuntos de 10 bolas de colores

Para mayor claridad, consideremos los siguientes dos conjuntos de 10 bolas de colores (donde cualquier par de bolas del mismo color es indistinguible):

Conjunto 1




Composición del conjunto 1:

- 8 bolas rojas
- 2 bolas azules

{roja, roja, roja, roja, roja, roja, roja, azul, azul}

Conjunto 2



Composición del conjunto 2:

- 4 bolas rojas
- 3 bolas azules
- 2 bolas amarillas
- 1 bola verde

{roja, roja, roja, roja, azul, azul, azul, amarilla, amarilla, verde}

ENTROPÍA: OTRA MEDIDA DE DIVERSIDAD CON IMPORTANTES APLICACIONES EN LA TEORÍA DE LA INFORMACIÓN

Conjunto 1

$$P(r, r, r, r, r, r, r, r, b, b) = \frac{8}{10} \frac{8}{10} \frac{8}{10} \frac{8}{10} \frac{8}{10} \frac{8}{10} \frac{8}{10} \frac{8}{10} \frac{2}{10} \frac{2}{10}$$
$$= \left(\frac{8}{10}\right)^8 \left(\frac{2}{10}\right)^2 = 0.0067108864.$$


Conjunto 2

$$P(r, r, r, r, b, b, b, y, y, g) = \frac{4}{10} \cdot \frac{4}{10} \cdot \frac{4}{10} \cdot \frac{4}{10} \cdot \frac{3}{10} \cdot \frac{3}{10} \cdot \frac{3}{10} \cdot \frac{2}{10} \cdot \frac{2}{10} \cdot \frac{1}{10}$$
$$= \left(\frac{4}{10}\right)^4 \left(\frac{3}{10}\right)^3 \left(\frac{2}{10}\right)^2 \left(\frac{1}{10}\right)^1 = 0.0000027648.$$

Dos conjuntos de 10 bolas de colores

Para mayor claridad, consideremos los siguientes dos conjuntos de 10 bolas de colores (donde cualquier par de bolas del mismo color es indistinguible):

Conjunto 1




Composición del conjunto 1:

- 8 bolas rojas
- 2 bolas azules

{roja, roja, roja, roja, roja, roja, roja, roja, azul, azul}

Conjunto 2



Composición del conjunto 2:

- 4 bolas rojas
- 3 bolas azules
- 2 bolas amarillas
- 1 bola verde

{roja, roja, roja, roja, azul, azul, azul, amarilla, amarilla, verde}

ENTROPÍA

Definimos la entropía así: comenzamos con la probabilidad de obtener una secuencia exacta de elementos al extraerlos de un conjunto con reemplazo. Aplicamos el logaritmo y lo dividimos entre el número total de elementos.


Set 1: {red, red, red, red, red, red, red, red, blue, blue} (eight red balls, two blue balls)

$$Entropy = -\frac{1}{10} \log_2 = \left[\left(\frac{8}{10} \right)^8 \left(\frac{2}{10} \right)^2 \right] - \frac{8}{10} \log_2 \left(\frac{8}{10} \right) = \frac{2}{10} \log_2 \left(\frac{2}{10} \right) \quad 0.722$$

Set 2: {red, red, red, red, blue, blue, blue, yellow, yellow, green}

$$Entropy = -\frac{1}{10} \log_2 \left[\left(\frac{4}{10} \right)^4 \left(\frac{3}{10} \right)^3 \left(\frac{2}{10} \right)^2 \left(\frac{1}{10} \right)^1 \right]$$
$$= -\frac{4}{10} \log_2 \left(\frac{4}{10} \right) - \frac{3}{10} \log_2 \left(\frac{3}{10} \right) - \frac{2}{10} \log_2 \left(\frac{2}{10} \right) - \frac{1}{10} \log_2 \left(\frac{1}{10} \right) = 1.846$$


¿CÓMO USAMOS LA ENTROPÍA PARA DECIDIR COMO DIVIDIR LOS DATOS (POR EDAD O PLATAFORMA)?




CRITERIOS DE DIVISIÓN

MÉTRICA	CONCEPTO PRINCIPAL	CÁLCULO MATEMÁTICO	SENSIBILIDAD
Exactitud (Accuracy)	Frecuencia de clasificación correcta absoluta.	$\frac{\text{Aciertos}}{\text{Total}}$	Baja. A menudo es insuficiente para captar sutilezas en la distribución interna de conjuntos mixtos.
Índice Gini	Probabilidad de clasificar incorrectamente un elemento aleatorio (Medida de impureza).	$1 - \sum (p_i)^2$	Cómputo rápido. Escala de 0 (puro) a 0.5 (diverso). Penaliza levemente subconjuntos mixtos.
Entropía	Medida de desorden fundamentada en la teoría de la información de Shannon.	$-\sum p_i \log_2(p_i)$	Más estricta computacionalmente (uso de logaritmos). Favorece fuertemente divisiones que generan hojas extremadamente puras.


SEGUNDO PASO PARA CONSTRUIR EL MODELO: ITERACIÓN



SEGUNDO PASO PARA CONSTRUIR EL MODELO: ITERACIÓN



ARBOL DE DESICIÓN FINAL



ÚLTIMO PASO: CUÁNDO DEJAR DE ITERAR Y OTROS HIPER PARÁMETROS

01

No dividas un nodo si el cambio en la precisión, el índice de Gini o la entropía está por debajo de cierto umbral.

02

No dividas un nodo si tiene menos de un número determinado de muestras.

03

Divide un nodo sólo si ambas hojas resultantes contienen al menos un número determinado de muestras.

04

Deja de construir el árbol una vez que alcances una profundidad determinada.

TRANSPARENCIA E IMPLEMENTACIÓN REAL



La Ventaja de la “Caja Blanca”

A diferencia de las Redes Neuronales (‘cajas negras’), los árboles proveen jerarquías lógicas completamente legibles y auditables por humanos, un requisito legal en finanzas y sectores regulados.




Diagnóstico Médico Clínico

Trascienden la predicción binaria (‘enfermo’ vs ‘sano’). Revelan exactamente qué combinaciones de variables (historial, presión arterial, edad) fueron determinantes para llegar a la conclusión.



Optimización y Recomendaciones


Modelan dinámicas demográficas complejas (ej. Engagement en apps). Sirven como la arquitectura base para sistemas algorítmicos avanzados y ganadores de premios (Random Forest, Gradient Boosting).



ENSEMBLE LEARNING: LA SABIDURÍA DE LAS MULTITUDES


¿QUÉ ES ENSEMBLE LEARNING?

Principio fundamental: Combinar múltiples modelos (weak learners) para crear un predictor más robusto y preciso.




TIPOS DE ENSEMBLE LEARNING

Bagging



Parallel

Boosting



Sequential

BAGGING: VOTACIÓN EL ENSEMBLE MÁS SIMPLE

Entrenar varios clasificadores distintos (SVM, Logistic Regression, Decision Tree, etc.) y agregar sus predicciones.

Hard Voting (clasificación):


$$\hat{y} = \text{mode}(\hat{y}_1, \hat{y}_2, \dots, \hat{y}_M)$$

Soft Voting (probabilidades):

$$\hat{y} = \arg \max_k \sum_{m=1}^M p_m(y = k|x)$$

Regresión (promedio):

$$\hat{y} = \frac{1}{M} \sum_{m=1}^M \hat{y}_m$$



¿POR QUÉ FUNCIONA ENSEMBLE LEARNING?


Requisito clave: Los modelos deben ser DIVERSOS (errores no correlacionados)

Matemática básica:

Para M modelos independientes con error ϵ cada uno:

$$\text{Error}_{\text{ensemble}} \approx \frac{\epsilon}{\sqrt{M}}$$


Ley de los grandes números: Con suficientes weak learners independientes, el ensemble converge a la predicción correcta



BOOSTING

Boosting no solo promedia modelos: construye una secuencia donde cada etapa intenta corregir errores anteriores.

Hoy solo instalamos la intuición. XGBoost, LightGBM, CatBoost, early stopping e HPO pertenecen a la Sesión 2.



GRACIAS