

MACHINE LEARNING · CLASE 3

Time Series Forecasting

Del pronóstico ingenuo al SARIMAX: los fundamentos estadísticos para predecir el futuro

Basado en *Time Series Forecasting in Python* — Marco Peixeiro · Partes 1 y 2

Tres bloques, un mismo procedimiento

#	Bloque	Contenido	Demos (notebooks)	Tiempo
1	Fundamentos	Qué es una serie de tiempo, baselines, MAPE, estacionariedad, ACF	Demo 1: CH02 · Demo 2: CH03	50 min
2	La familia ARIMA	MA(q), AR(p), ARMA, AIC, residuos, ARIMA(p,d,q)	Demo 3: CH04/CH05 · Demo 4: CH07	50 min
3	Estacionalidad y exógenas	STL, SARIMA(p,d,q)(P,D,Q)m, SARIMAX, cierre	Demo 5: CH08 · Demo 6: CH09	50 min

Entre bloques: pausa corta. Cada demo usa un notebook anotado que los estudiantes pueden volver a correr en casa.

¿Cuánto ganará J&J por acción en 1980?



Al terminar la clase podrás...

1 • Evaluar

Dividir train/test respetando el tiempo y comparar contra un **baseline** con MAPE.

2 • Diagnosticar

Probar **estacionariedad** (ADF) y leer **ACF / PACF**.

3 • Modelar

Elegir y ajustar **AR, MA, ARMA, ARIMA y SARIMA** con el procedimiento general (AIC + residuos).

4 • Criticar


Usar **SARIMAX** con variables externas y detectar resultados “demasiado buenos”.

BLOQUE 1 • 50 MIN

Fundamentos: el tiempo tiene orden

Series de tiempo, baselines, MAPE, caminata aleatoria, estacionariedad y autocorrelación

CROSS-VALIDATION



PREGUNTA PARA LA CLASE

Si separo entrenamiento y prueba
mezclando las fechas al azar, ¿qué
puede salir mal?

Pensar un minuto y comentar con la clase.

¿POR QUÉ NO ES UNA REGRESIÓN COMÚN?

El orden es sagrado: prohibido mezclar

Regresión “clásica”

Filas independientes. Puedes mezclar (*shuffle*) y partir al azar.

Serie de tiempo

El futuro depende del pasado. Si mezclas, entrenas con el futuro para predecir el pasado: **sesgo de anticipación** (*look-ahead bias*).

División correcta:

train (pasado)

test

- El test = **los datos más recientes**.
- Su tamaño = el **horizonte** que necesita el negocio.
- A veces no hay más *features* que la propia serie.

CONCEPTO

Una serie de tiempo es una secuencia de datos ordenada en el tiempo

Idea central: el índice no es un número de fila cualquiera; es **el momento** en que ocurrió el dato.

DESCOMPOSICIÓN

Toda serie se puede pensar como tres capas

Tendencia

El movimiento lento de fondo: la serie sube o baja gradualmente.

Como la línea del bajo en una canción.

Estacionalidad

Un patrón que se repite en un periodo fijo: cada año, cada semana, cada día.


Como el ritmo de la batería.

Residuo

Lo que no explican las dos anteriores: variación aleatoria, ruido.


Como el ruido de la grabación.

Serie observada = tendencia + estacionalidad + residuo. En el Bloque 3 lo haremos en código con **STL**.



DESCOMPOSICIÓN

Toda serie se puede pensar como tres capas



El modelo es solo un paso de ocho

1
Definir la meta

2 ¿Determinar qué debemos pronosticar?

3
Fijar el horizonte

4
Recolectar datos

5
Desarrollar el modelo

6
Desplegar

7
Monitorear

8
Nuevos datos → reentrenar

Ejemplo del libro: vas de camping en un mes y necesitas elegir la bolsa de dormir → pronosticar la temperatura mínima nocturna de esa semana (horizonte = 7 días).

En qué se diferencia la predicción de series temporales de otras tareas de regresión

Las series temporales tienen un orden

El primer concepto que hay que tener en cuenta es que las series temporales tienen un orden, y no podemos cambiar ese orden al modelarlas. En la predicción de series temporales, expresamos los valores futuros como una función de los valores pasados.

Las series temporales a veces no tienen características

Es posible realizar pronósticos de series temporales sin utilizar otras características que no sean la propia serie temporal.

Primero, el modelo más tonto posible

Baseline	Qué pronostica	Cuándo sirve / qué ignora
Media histórica	Promedio de todo el pasado	Ignora tendencia y estacionalidad
Media del último año	Promedio de los 4 trimestres más recientes	Aprovecha que lo reciente pesa más
Último valor	Repetir el último dato observado	Ideal si la serie es una caminata aleatoria
Naive estacional	Repetir el mismo periodo del ciclo anterior	Captura la estacionalidad gratis

Un baseline es la vara de medir: si tu modelo sofisticado no le gana, **no sirve**.

MÉTRICA

MAPE: ¿en qué porcentaje me equivoco, en promedio?

$$\text{MAPE} = (100 / n) \cdot \sum | (y_i - \hat{y}_i) / y_i |$$

```
def mape(y_true, y_pred):  
    return np.mean(np.abs((y_true -  
y_pred) / y_true)) * 100
```

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{A_i - F_i}{A_i} \right| \times 100$$

Mean absolute percentage error (MAPE): A_i es el valor real en el momento i , y F_i es el valor pronosticado en el momento i ; n es simplemente el número de predicciones (Forecasting).

Ventajas

Fácil de explicar a un gerente (“me equivoco 5 %”) y comparable entre series de distinta escala.

Cuidado

No funciona si hay valores reales iguales a 0 y se infla con valores muy pequeños. Alternativas: MAE, MSE.

DEMO 1 • 9 MIN


Baselines para J&J

```
TimeSeriesForecastingInPython / CH02 / CH02_anotado.ipynb
```

- Celdas 1–4: cargar **jj.csv** y graficar (zona gris = 1980).
- Celda del split: **train = df[:-4], test = df[-4:]** — sin mezclar.
- Los 4 baselines + **mape()**: pide al salón que prediga el resultado antes de ejecutar.
- Cierra con la gráfica de barras: el **naive estacional** gana.

RESULTADO DE LA DEMO 1

El baseline a vencer: 11.6 % de MAPE



Lección 1: lo reciente pesa más que lo remoto.

Lección 2: ignorar la estacionalidad castiga (último valor).

Lección 3: capturar el ciclo, aun de forma ingenua, gana.

Valor de Hoy = ayer + un paso al azar

$$y_t = C + y_{t-1} + \varepsilon_t$$

```
steps = np.random.standard_normal(1000)
random_walk = np.cumsum(steps)
```

ε_t = **ruido blanco**: valores aleatorios independientes, media 0 y varianza constante.

Analogía: alguien que da un paso al azar cada segundo. Su posición es la suma de todos sus pasos.




Figure 3.2 Visualizing the construction of our simulated random walk. As you can see, our initial value is 0. Then, since the constant was also set to 0, the value of our random walk at any point in time is simply the cumulative sum of random numbers, or white noise.

¿Por qué importa?


Muchas series reales se comportan así: precios de acciones en el corto plazo (en la Demo 2, GOOGL).

La trampa visual

Aunque es puro azar, **parece** tener tendencias. El ojo ve patrones que no existen: necesitamos pruebas estadísticas. [Simulación](#)

ESTACIONARIEDAD

Una serie estable: sus reglas no cambian con el tiempo




Estacionaria = **media, varianza y autocorrelación constantes** en el tiempo.

🌴 Temperatura en una ciudad ecuatorial: siempre alrededor del mismo promedio.

☕ Un café enfriándose: su media cambia todo el tiempo.


AR, MA y ARMA **la exigen**.

Una serie no estacionaria



Algunos ejemplos de procesos no estacionarios son el paseo aleatorio, con o sin deriva (un cambio lento y constante), y las tendencias determinísticas (tendencias que son constantes, positivas o negativas, independientes del tiempo durante toda la vida de la serie).

Transformaciones en contexto de series temporales



Una **transformación** es una operación matemática que se aplica a una serie temporal con el fin de hacerla estacionaria.

La diferenciación es una transformación que calcula el cambio de un intervalo de tiempo a otro. Esta transformación es útil para estabilizar la media.

La aplicación de una función logarítmica a la serie puede estabilizar su varianza.

AR, MA y ARMA **exigen que la serie sea estacionaria.**

¿CÓMO LO PROBAMOS?

La prueba ADF (Augmented Dickey-Fuller)

Hipótesis nula (H0)

La serie tiene raíz unitaria → **NO es estacionaria**.

Regla de decisión

$p\text{-valor} < 0.05 \rightarrow$ rechazamos H0 → **es estacionaria**.

Estadístico es un número negativo grande = más evidencia.

Nemotecnia: “p pequeño = serie tranquila”.



```
from statsmodels.tsa.stattools import adfuller

res = adfuller(serie)
print('ADF:', res[0])
print('p-valor:', res[1])
```

Serie (Demo 2)	p-valor
Caminata aleatoria	0.77 → no estacionaria
Caminata diferenciada	$\approx 0 \rightarrow$ estacionaria

La prueba lleva el nombre de los estadistas David Dickey y Wayne Fuller, quienes la desarrollaron en 1979

¿Cuánto se parece hoy a ayer, a anteayer...?



DIFERENCIACIÓN


Pasar de niveles a cambios, y un procedimiento para identificar el azar

$$y'_t = y_t - y_{t-1}$$

```
serie_diff = np.diff(serie, n=1)
```

En vez de modelar “cuánto vale”, modelamos “cuánto cambió”.
Suele eliminar la tendencia.

⚠ Se pierde el primer dato. Para volver a la escala original: **suma acumulada**.



DEMO 2 · 8 MIN

¿Es Google una caminata aleatoria?

TimeSeriesForecastingInPython / CH03 / CH03_anotado.ipynb

- Simulación: caminata aleatoria con **np.cumsum** (¡parece tener tendencia!).
- Serie estacionaria vs. no estacionaria: media y varianza acumuladas.
- **adfuller** y **plot_acf** antes y después de diferenciar.
- Mismo procedimiento sobre **GOOGL.csv** → se comporta como caminata aleatoria.

Tres ideas para llevarse al receso

Evaluar

Split temporal, horizonte de negocio y un baseline siempre.

Diagnosticar

ADF: $p < 0.05 \rightarrow$ estacionaria. ACF: ¿cuánta memoria tiene la serie?

Transformar

Diferenciar convierte niveles en cambios y suele dar estacionariedad.

🤔 Pregunta: si la ACF de la serie diferenciada **sí** tiene barras significativas... ¿qué significa?

BLOQUE 2 · 50 MIN

El pasado explica el futuro: MA, AR, ARMA y ARIMA

Cómo leer la memoria de una serie, cómo elegir un modelo con el AIC y cómo saber si quedó bien


El presente arrastra las sorpresas recientes

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

💡 Un pedido gigante e inesperado afecta las ventas de hoy y de los próximos q días... y luego su efecto **desaparece por completo**.



⚠️ No es la “media móvil” para suavizar gráficos.

🔑 Firma: la **ACF se corta** de golpe después del lag q .



Definición de un proceso MA(q)

Pongamos esto en práctica utilizando nuestros datos sobre el volumen de ventas de widgets de la empresa XYZ Widget Company. El conjunto de datos contiene información sobre el volumen de ventas de 500 días, a partir del 1 de enero de 2019. Seguiremos los pasos descritos en la figura de la derecha y determinaremos el orden del proceso de media móvil subyacente.



DEMO 3 · 6 MIN

DEMO MA(q) en el código

TimeSeriesForecastingInPython / CH04_anotado.ipynb



- CH04: **adfuller** → **np.diff** → **plot_acf**: corte en lag 2 → MA(2).

El presente arrastra los valores recientes

$$y_t = C + \psi_1 y_{t-1} + \dots + \psi_p y_{t-p} + \varepsilon_t$$

💡 Inercia: si la semana pasada la tienda estuvo llena, esta semana probablemente también. El efecto se diluye, pero **nunca se corta de golpe**.

👴👦👦 **PACF**: el parecido del nieto con el abuelo *descontando lo que ya explica el padre*.





🔑 Firma: la ACF decae lentamente y la **Partial autocorrelation function (PACF) se corta** después del lag p .


PROCESO DE MEDIA MÓVIL · MA(q)

Definición de un proceso AR(p)

Al igual que con el proceso de media móvil, existe una forma de determinar el orden p de un proceso autorregresivo estacionario. Podemos ampliar los pasos necesarios para identificar el orden de una media móvil



Pronosticar, observar, reentrenar, repetir



¿Por qué?

Un MA(q) solo “ve” q pasos al futuro; más allá, pronostica la media. Además, así funciona en producción.

Analogía

El pronóstico del clima se actualiza cada día con la observación nueva; nadie pronostica el mes completo de una vez.

DEMO 3 • 6 MIN

DEMO AR(p)



TimeSeriesForecastingInPython / CH05_anotado.ipynb

- CH05: la ACF decae → **plot_pacf** → corte en lag 3 → AR(3).
- CH05: la simulación AR(2) con **ArmaProcess** confirma la regla.
- Solo mostrar; el pronóstico completo queda para casa.

PROCESO DE MEDIA MÓVIL • MA(q)

Definición de un proceso ARMA(p, q)

El proceso autorregresivo de media móvil es una combinación del proceso autorregresivo y del proceso de media móvil. Se denota como modelo ARMA(p, q), donde p es el orden del proceso autorregresivo y q es el orden del proceso de media móvil.



Premiar el ajuste, multar la complejidad

$$AIC = 2k - 2\ln(\hat{L})$$

k = número de parámetros

$\hat{L}$ = verosimilitud (qué tan bien ajusta)

Menor AIC = mejor modelo. Solo sirve para comparar modelos sobre los mismos datos.

El criterio de información de Akaike fue formulado por el estadístico Hirotugu Akaike. Originalmente se denominó «un criterio de información»



Analogía del examen

Te dan puntos por cada respuesta correcta (ajuste) pero te quitan puntos por cada hoja de fórmulas extra que lleves (parámetros).

Por qué importa

Sin la multa, siempre ganaría el modelo más grande: **sobreajuste**. El AIC es la navaja de Ockham convertida en número.



PROCESO DE MEDIA MÓVIL • MA(q)

Selección de un modelo mediante el

	(p,q)	AIC
0	(1, 1)	2801.407785
1	(2, 1)	2802.906070
2	(1, 2)	2802.967762
3	(0, 3)	2803.666793
4	(1, 3)	2804.524027
5	(3, 1)	2804.588567
6	(2, 2)	2804.822282
7	(3, 3)	2805.947168
8	(2, 3)	2806.175380
9	(3, 2)	2806.894930
10	(0, 2)	2812.840730
11	(0, 1)	2891.869245
12	(3, 0)	2981.643911
13	(2, 0)	3042.627787
14	(1, 0)	3207.291261
15	(0, 0)	3780.418416

Inicializaremos una lista vacía para almacenar cada combinación (p, q) y su AIC correspondiente.

Luego, recorreremos cada combinación (p, q) y ajustaremos un modelo ARMA(p, q) a nuestros datos.

Calcularemos el AIC y guardaremos el resultado.




Figure 6.8 The general modeling procedure for an ARMA(p,q) process

Lo que sobra debe ser puro ruido

Consideremos nuestro proceso observado, puede ser expresado en la siguiente ecuación

$$y_t = 0.33y_{t-1} + 0.9\epsilon_{t-1} + \epsilon_t$$

Ahora supongamos que ajustamos un modelo ARMA(1,1) a nuestro proceso y estimamos los coeficientes del modelo a la perfección, de modo que el modelo se exprese como la ecuación.

$$\hat{y}_t = 0.33y_{t-1} + 0.9\epsilon_{t-1}$$

Los residuos serán la diferencia entre los valores que nos da nuestro modelo y los valores observados en nuestro proceso observado. En otras palabras, los residuos son la diferencia entre la primera y segunda ecuación

$$\begin{aligned}\text{residuals} &= 0.33y_{t-1} + 0.9\epsilon_{t-1} + \epsilon_t - (0.33y_{t-1} + 0.9\epsilon_{t-1}) \\ \text{residuals} &= \epsilon_t\end{aligned}$$

Como se puede observar en la tercera ecuación, en una situación ideal los residuos de un modelo son ruido blanco. Esto indica que el modelo ha captado toda la información predictiva, y solo queda una fluctuación aleatoria que no se puede modelar. Por lo tanto, los residuos no deben estar correlacionados y tener una distribución normal para que podamos concluir que contamos con un buen modelo para realizar pronósticos.

DEMO 3 · 6 MIN

DEMO ARMA(p,q)

`TimeSeriesForecastingInPython / CH05_anotado.ipynb`

- CH06: la simulación ARMA con **ArmaProcess** confirma la regla.
- Solo mostrar; el pronóstico completo queda para casa.

ARIMA(P, D, Q)

La I de "integrado": el modelo diferencia por ti

p

valores pasados (AR)

d

cuántas diferencias para ser estacionaria

q

sorpresas pasadas (MA)

Encontrar **d** en J&J con ADF sucesivas:

Serie	p-valor ADF
Original	1.00
1 diferencia	0.91
2 diferencias	0.006 → d = 2

```
from statsmodels.tsa.statespace.sarimax import SARIMAX
```

```
modelo = SARIMAX(train, order=(3, 2, 3))  
res = modelo.fit(dispatch=False)  
res.get_prediction(80, 83)
```

Pronósticos ya en la **escala original**.

Autoregressive integrated moving average model

Un proceso de media móvil integrada autorregresiva (ARIMA) es la combinación de los procesos $AR(p)$ y $MA(q)$, pero en términos de la serie diferenciada. Se denota como $ARIMA(p,d,q)$, donde p es el orden del proceso $AR(p)$, d es el orden de integración y q el orden del proceso $MA(q)$. La integración es lo contrario de la diferenciación, y el orden de integración d es igual al número de veces que se ha diferenciado la serie para que sea estacionaria.





Figure 7.4 General modeling procedure for using the $ARIMA(p,d,q)$ model. Notice the addition of a step where we specify the parameter d for the $ARIMA(p,d,q)$ model. Here, d is simply the minimum number of times a series must be differenced to become stationary.

La tabla que hay que memorizar

Modelo	El presente depende de...	ACF	PACF
MA(q)	sorpresas pasadas	se corta en q	decae
AR(p)	valores pasados	decae	se corta en p
ARMA(p,q)	ambos	decae	decae
Ruido blanco	nada	nada significativo	nada significativo

Requisito previo: la serie debe ser **estacionaria** (si no, diferenciar primero).


DEMO 4 · 16 MIN

ARIMA vs. el baseline en J&J

TimeSeriesForecastingInPython / CH07 / CH07_anotado.ipynb

- ADF sucesivas: $1.00 \rightarrow 0.91 \rightarrow 0.006 \Rightarrow \mathbf{d = 2}$.
- **optimize_ARIMA**: 16 modelos, tabla por AIC $\Rightarrow$ ARIMA(3,2,3).
- **plot_diagnostics** + Ljung-Box (versión corregida): ¿ruido blanco?
- **get_prediction(80, 83)** y MAPE: 11.6 % $\rightarrow$ 1.7 %.

De 11.6 % a 1.7 %: siete veces menos error



BLOQUE 3 · 50 MIN

Estacionalidad y variables externas

SARIMA para patrones que se repiten; SARIMAX para usar información de afuera;
y un cierre para seguir solos

Patrones que vuelven en un periodo fijo: m

Frecuencia de los datos	Ciclo típico	m
Mensual	anual	12
Trimestral	anual	4
Diaria	semanal	7
Horaria	diario	24

Cómo detectarla


Gráfico con líneas verticales en cada ciclo · picos en el mismo mes · descomposición STL · ACF con picos en m, 2m...

Por qué no basta ARIMA

Para “recordar” un año atrás, un ARIMA necesita muchos rezagos: ARIMA(11,2,3) en la Demo 5.

DESCOMPOSICIÓN STL

Pasajeros aéreos 1949–1960, separados en capas



```
from statsmodels.tsa.seasonal import STL
STL(serie, period=12).fit()
```

Tendencia: crece sin parar.

Estacionalidad: pico cada verano.

Residuo: ruido sin patrón.

SARIMA(p,d,q)(P,D,Q)M

Una segunda capa que mira m periodos atrás

(p, d, q)

Parte **no estacional**: los meses inmediatamente anteriores.

Para diciembre, mira noviembre y octubre.

(P, D, Q)_m

Parte **estacional**: los mismos meses de ciclos anteriores.

Para diciembre, mira el diciembre pasado y el antepasado.

```
SARIMAX(train, order=(2, 1, 1), seasonal_order=(1, 1, 2, 12))
```

D = diferencias estacionales: $y_t - y_{t-m}$ (restar el valor de hace m periodos).

Frecuencia adecuada m según los datos

(P, D, Q)m

Parte **estacional**: los mismos meses de ciclos anteriores.

Para diciembre, mira el diciembre pasado y el antepasado.

Table 8.1 Appropriate frequency m depending on the data

Data collection	Frequency m
Annual	1
Quarterly	4
Monthly	12
Weekly	52

Table 8.2 Appropriate frequency m for daily and sub-daily data

Data collection	Frequency m				
	Minute	Hour	Day	Week	Year
Daily				7	365
Hourly			24	168	8766
Every minute		60	1440	10080	525960
Every second	60	3600	86400	604800	31557600

DIFERENCIACIÓN ESTACIONAL

Identificación de patrones estacionales en una serie

Intuitivamente, sabemos que tiene
temporal
sentido aplicar el modelo SARIMA
a datos que presentan un patrón
estacional.




Figure 8.1 Monthly total number of air passengers for an airline, from January 1949 to December 1960. You'll notice a clear seasonal pattern in the series, with peak traffic occurring toward the middle of each year.




Figure 8.3 Highlighting the seasonal pattern in the monthly number of air passengers. The dashed vertical lines separate periods of twelve months. We can clearly see how a peak occurs in the middle of each year, and there is a very similar pattern for the beginning and end of each year. This observation is usually enough to determine that the dataset is seasonal.

DIFERENCIACIÓN ESTACIONAL


Descomposición de series temporales

Es una tarea estadística que separa la serie temporal en sus tres componentes principales: un componente de tendencia, un componente estacional y los residuos.

El componente de tendencia representa el cambio a largo plazo en la serie temporal. Este componente es responsable de que las series temporales aumenten o disminuyan con el tiempo.

El componente estacional es el patrón periódico de la serie temporal. Representa las fluctuaciones repetidas que ocurren durante un período fijo de tiempo.

Por último, los residuos, o el ruido, expresan cualquier irregularidad que no pueda explicarse mediante la tendencia o el componente estacional.



Autoregressive integrated moving average (SARIMA)

El modelo de media móvil integrada autorregresiva estacional (SARIMA) agrega parámetros estacionales al modelo ARIMA(p,d,q).

Se denota como SARIMA(p,d,q)(P,D,Q)m, donde P es el orden del proceso AR(P) estacional, D es el orden de integración estacional, Q es el orden del proceso MA (Q), y m es la frecuencia, o el número de observaciones por ciclo estacional.

Tenga en cuenta que un modelo SARIMA(p,d,q)(0,0,0)m es equivalente a un modelo ARIMA(p,d,q).





Figure 8.7 General modeling procedure for the SARIMA model. Note that we can set P, D, and Q to 0 to obtain an ARIMA(p,d,q) model.


DEMO 5 · 12 MIN

SARIMA para pasajeros aéreos

TimeSeriesForecastingInPython / CH08 / CH08_anotado.ipynb

- Gráficos de estacionalidad + **STL(period=12)**.
- ADF: $d = 1$ no basta; celda original **np.diff(n=12)** vs. la corregida.
- Búsquedas en malla **desactivadas** (EJECUTAR_BUSQUEDA = False).
- ARIMA(11,2,3) vs. SARIMA(2,1,1)(1,1,2)₁₂ vs. naive: MAPE.

Modelar el ciclo explícitamente gana, y con menos parámetros



SARIMA + X: sumar información de afuera

$$y_t = \text{SARIMA}(p,d,q)(P,D,Q)_t + \beta_1 X^1_t + \beta_2 X^2_t + \dots + \beta_n X^n_t$$



Analogía

Para pronosticar ventas de helado miras las ventas pasadas (SARIMA) **y** el pronóstico de temperatura (X).

En la Demo 6

y = PIB real de EE. UU. · X = consumo, inversión, gasto público, ingreso disponible, precios (IPC).

En código

```
SARIMAX(y, exog=X, order=..., seasonal_order=...)
```

Para pronosticar y mañana, necesitas X de mañana

El problema

Si X también es desconocida en el futuro, tienes que pronosticarla... y sus errores se suman a los tuyos.

X que sí conoces

Feriados, promociones que tú decides, precio que tú fijas, calendario escolar.

X que no conoces

Clima de dentro de 3 meses, consumo del próximo trimestre, tipo de cambio.

Estrategia del libro

Pronosticar **un paso** a la vez y reentrenar.

No elijas variables por p-valor

El p-valor dice si $\beta \neq 0$, no si la variable ayuda a pronosticar. Que decida el **AIC**.

DEMO 6 • 9 MIN

SARIMAX para el PIB, y una sospecha

TimeSeriesForecastingInPython / CH09 / CH09_anotado.ipynb

- **sm.datasets.macrodta:** $y = \text{realgdp}$, $X = 5$ variables.
- ADF $\rightarrow d = 1$ • búsqueda desactivada $\rightarrow \text{SARIMAX}(3,1,3)(0,0,0)_4$.
- **recursive_forecast:** 7 trimestres, 1 paso a la vez vs. último valor.
- 🧪 Nota del experto: el 0.26 % “demasiado bueno”.

Desconfía de lo que sale demasiado bien

Método (7 trimestres, 1 paso adelante)	MAPE	Lectura
Último valor (baseline)	0.74 %	la vara
SARIMAX, código del libro	0.70 %	casi empate
SARIMAX + X del mismo trimestre	0.26 %	fuga de información

PIB ≈ consumo + inversión + gasto público + exportaciones netas. Si le das al modelo las piezas del mismo trimestre, casi le das la respuesta. En la vida real se publican **al mismo tiempo** que el PIB.

Pregunta de oro: ¿tendría estos datos en el momento de pronosticar?

Mapa de decisión: ¿qué modelo uso?

Pregunta	Decisión
¿Es estacionaria?	No → diferenciar (d) · Estacional → también D
¿La diferencia es ruido blanco?	Sí → caminata aleatoria → último valor
¿Hay un ciclo que se repite?	Sí → SARIMA con su m · No → ARIMA
¿Hay variables externas conocidas hacia el futuro?	Sí → SARIMAX · No → no las fuerces
Siempre	Baseline + búsqueda por AIC + residuos + MAPE en test

PARA SEGUIR POR TU CUENTA

Lo que viene en el libro (y por qué ya estás listo)

Cap. 10 · VAR

Varias series que se influyen entre sí (p. ej., ingreso y consumo).

Cap. 11 · Proyecto

Proyecto integrador: recetas de antidiabéticos en Australia con SARIMA.

Parte 3 · Deep learning

Ventanas de datos, redes densas, LSTM y CNN con Keras.

Parte 4 · Prophet

Automatizar el pronóstico a escala.

Lo que no cambia en ningún modelo: **split temporal, baseline, métrica, calculo de residuos y sospecha.**

Tres preguntas, un minuto cada una

1

¿Por qué no puedes usar **train_test_split** con *shuffle* en una serie de tiempo?

2

La ACF de la serie diferenciada se corta en el lag 2 y la PACF decae. ¿Qué modelo propones?

3

Tu SARIMAX tiene 0.1 % de MAPE usando como X el clima del mismo día. ¿Qué te preocupa?

¿Preguntas?